

基于 YOLOv8n 的钢材表面缺陷检测 优化实验

题目：5C 轻量级实时目标检测优化 工业质检场景



小组成员

刘紫涵、刘宇欣、王芯、李钰、余玉媛



汇报日期

2026年6

研究背景与动机



工业质检的核心价值

钢材表面的裂纹、划痕、麻面等缺陷直接决定产品质量与安全合规性。在智能制造体系中，建立快速、精准的缺陷检测机制，是保障生产良率、规避安全风险的关键前置环节。



传统人工检测的局限性

依赖肉眼的传统方式存在效率低、主观性强、稳定性差等痛点。质检员的经验差异与疲劳状态会导致判定标准不一，且长时间作业极易出现注意力下降，大幅增加缺陷漏检与误判的风险。



深度学习技术的变革机遇

以YOLO系列为代表的目标检测模型，能够实现缺陷的自动识别与精准定位，突破了人工检测的效率瓶颈。其检测速度与精度远超人力，可满足现代化高速生产线的实时在线检测需求。



边缘部署的核心挑战与目标

高性能模型体积大、计算成本高，难以适配算力受限的工业边缘设备。本研究旨在平衡精度与效率，通过模型轻量化技术，在保持高检测准确率的前提下，显著降低复杂度，实现边缘端的实时推理。

核心问题与研究方法

针对YOLOv8n轻量级模型，我们的核心研究问题是探索有效的压缩方法，在不显著牺牲检测精度的前提下，最大程度降低模型复杂度，从而在资源受限的边缘设备上实现精度、推理速度与部署成本之间的最佳平衡。



01. 知识蒸馏 (Knowledge Distillation)

利用高性能“教师模型”(YOLOv8m)指导轻量“学生模型”(YOLOv8n)学习，让学生模型吸收教师模型的泛化知识。优势在于不改变学生模型的轻量化结构，也不增加最终部署的参数量与计算量，即可显著提升检测性能。



02. 结构化剪枝 (Structured Pruning)


通过算法识别并移除神经网络中贡献较小的卷积通道等结构单元，直接精简模型架构。该方法能显著减少参数量与计算量(FLOPs)，有效降低存储需求与推理延迟，优化效果直观且对部署友好。



关键参数分析：输入分辨率影响探究

对比 416×416 与 640×640 两种输入尺寸，分析分辨率对模型精度与推理速度的双重影响，为实际部署场景选择最优输入规格提供数据支撑。

实验设计



数据集: NEU-DET

源自真实热轧钢带场景，含1800张灰度图与6类典型缺陷。挑战在于图像分辨率低(200x200)，且部分缺陷纹理微弱、边界模糊，对模型特征提取能力要求极高。



基线模型: YOLOv8n

选用YOLOv8系列中最轻量的版本，作为轻量化部署的理想起点。其结构精简，在保证一定检测能力的同时，大幅降低了硬件资源消耗。

3.0M

参数量 (Params)

8.1G

计算量 (GFLOPs)



多维评价指标体系



检测精度


采用 mAP@0.5 与 mAP@0.5:0.95 双指标，全面衡量模型的检测与定位能力。



复杂度与速度

监控参数量(Params)与计算量(FLOPs)，并以FPS作为推理速度的核心衡量标准。

实验结果与分析 (1) - 基线模型



实验数据可视化显示：mAP@0.5 随分辨率提升有小幅增长，而每秒传输帧数 (FPS) 则急剧下降。这种此消彼长的关系是计算机视觉模型部署中精度与速度权衡的典型体现。

mAP@0.5 精度对比

640×640 (0.835) 略高于 416×416 (0.827)，更高的分辨率提供了更丰富的图像细节，利于小目标识别。

FPS 推理速度对比

416×416 (≈62.1 FPS) 是 640×640 (≈19.0 FPS) 的 3.3 倍，低分辨率显著提升了实时处理能力。

深层归因分析

高分辨率赋予模型更强的小目标与弱纹理捕捉能力，但成倍增加了计算量；低分辨率虽损失少量精度，却大幅降低了硬件负载，更适配工业实时检测场景。

场景化选型建议

输入分辨率的选择无绝对优劣，需根据项目对“检测精度”和“实时响应”的具体权重需求进行针对性取舍。

实验结果与分析 (2) - 知识蒸馏模型

核心发现：知识蒸馏的效果并非总能正向提升性能，其成败高度依赖于输入分辨率与教师模型的质量。我们以YOLOv8m为教师模型指导YOLOv8n训练，在不同分辨率下呈现出显著差异。

640×640 高分辨率：性能持平，结构无损

mAP从0.835至0.808，参数量保持3.0M不变。在高分辨率下，蒸馏成功保留了基线模型的高精度，实现了“零成本”的知识迁移。

416×416 低分辨率：教师受限，精度反降

mAP从0.827略降至0.812。由于教师模型在低分辨率下自身特征提取能力不足，误导了学生模型的学习方向，导致性能退化。



结论：知识蒸馏更适合作为高分辨率下的性能微调手段。在低分辨率场景中，需谨慎评估教师模型的有效性，避免负向迁移。

实验结果与分析 (3) - 结构化剪枝模型

对 YOLOv8n 模型实施 0.5 比例的通道剪枝后，在显著降低模型复杂度的同时，实现了推理速度的大幅跃升，达成了极佳的轻量化效果。

模型	尺寸	mAP@0.5	参数量(M)	FPS
Baseline	416×416	0.827	3.007	36.65
Pruned 0.5	416×416	0.783	1.059 (-64.8%)	50.94 (+38.9%)
Baseline	640×640	0.835	3.007	20.34
Pruned 0.5	640×640	0.804	1.059 (-64.8%)	34.96 (+71.8%)



极致模型压缩
0.5比例剪枝使参数量骤降64.8%，大幅减少存储占用，更利于边缘设备部署。




推理速度飞跃
高分辨率下FPS提升超70%，有效解决了复杂场景下的实时性瓶颈问题。



精度-速度的极佳平衡
剪枝后精度损失极小（mAP仅降0.031），结合微调策略可进一步恢复性能，在资源受限场景极具实用价值。

综合对比与结论

模型	输入尺寸	mAP@0.5	参数量 (M)	FPS
YOLOv8n Baseline	640×640	0.835	3.01	20.34
YOLOv8n Distilled	640×640	0.808	3.01	21.0
Pruned 0.5	640×640	0.804	1.06	34.96
Pruned 0.5	416×416	0.783	1.06	50.94



分辨率是关键权衡

高分辨率提升精度，低分辨率显著加快推理速度，需按需选择。



知识蒸馏用于微调

不改变模型结构，能在保持参数量的同时稳定或微增检测性能。



结构化剪枝是轻量化利器

大幅降低参数量与计算量，是边缘设备部署的最有效手段之一。



最优模型看应用场景

需结合精度要求、硬件成本与推理速度，进行多维度综合决策。

Thanks!

感谢老师、同学的聆听与指导!